Entwurf und Entwicklung eines KI-gestützten Verfahrens zur Auswahl einer (Meta-)Heuristik für das Touristentour-Design-Problem

Luca Hoffmann

Martin-Luther-Universität Halle-Wittenberg
Institut für Informatik

Betreuer: Prof. Dr. Matthias Müller-Hannemann
12. Dezember 2025

1. Motivation & Kontext
2. Touristen-Tour-Design-Problem
   - Verwandte Probleme
3. (Meta-)Heuristiken
4. Forschungsfragen & Ziele
5. Algorithmenauswahl
6. Merkmalsraum & Datengrundlage
7. Versuchsaufbau
8. Ergebnisse
   - Ergebnis I: Mittlere Score vs. Zeitlimit
   - Ergebnis II: Abstand zu VBS & Nähe zum Optimum
   - Ergebnis III: Score-Differenz vs. SBS (Wilcoxon-Test)
   - Ergebnis IV: Klassifikationsgüte & Fehlerbild
9. Diskussion & Einordnung
10. Ausblick
11. Fazit

Motivation & Kontext

- Machine Learning für kombinatorische Optimierung[Kot14; Hut+14]
- (Meta-)Heuristiken für Graphprobleme (z.B. Traveling-Salesman-Problem, Vehicle-Routing-Problem, ...)
- Touristentour-Design-Problem (TTDP) als praxisrelevanter, wenig untersuchter Spezialfall[Gav+14]
- Ziel: Algorithmenauswahl per Machine Learning für das TTDP

Touristentour-Design-Problem

Definition [Gav+14]

- **Gegeben**: vollständiger, metrischer Graph $G = (V, E)$
- Knoten mit Scores $s_v \geq 0 \quad \forall v \in V$
- Kanten mit Distanzen $d_{uv} \geq 0 \quad \forall u \in E, \forall v \in V$
- Budget B für maximale zulässige Distanz
- **Gesucht**: Rundtour mit Start = Ziel, Distanz $\leq$ B und maximalen Gesamtscore

Ziel: max. Score der besuchten Knoten bei begrenzter Gesamtdistanz

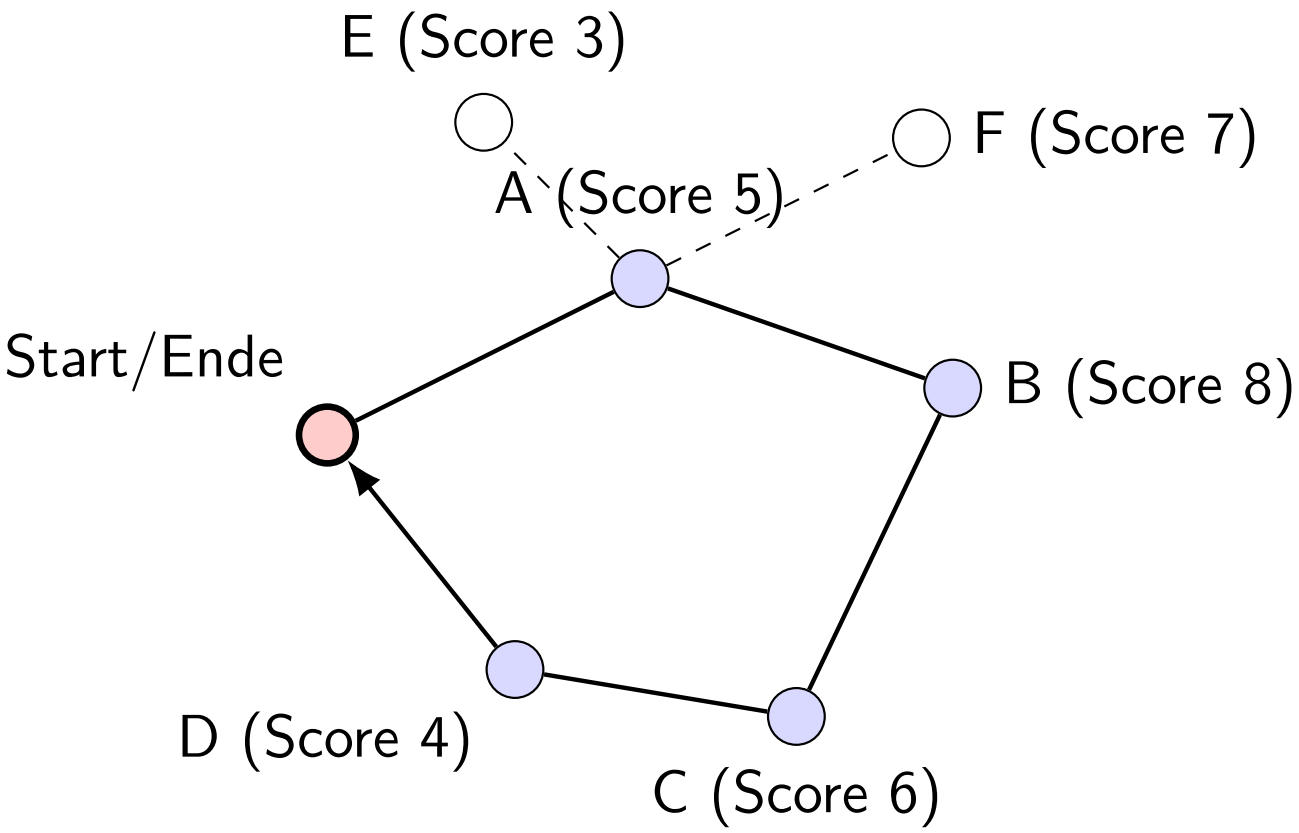

Start- / Endknoten

besuchte Attraktionen

nicht besuchte Attraktionen

Verwandte Probleme

- Vehicle Routing Problem[TV14]
- Traveling Salesman Problem[GP02]
- Orienteering Problem[VSO11; GLV87]
- Team-Orienteering-Problem[CGW96]
- Prize-Collecting TSP[FDG05; DMV95]

(Meta-)Heuristiken

- 4 (Meta-)Heuristiken

Greedy[Tsi84]

- Deterministisch
- Einfügeposition an Stelle des max Quotient aus hinzugefügter Score und zusätzliche Kosten

Greedy-Randomized-Adaptive-Search-Procedure (GRASP)[KZ16]

- zufällige Auswahl von Knoten aus Kandidatenliste während Tour-Konstruktion mit Greedy Algorithmus $\Rightarrow$ Diversifizierung der Konstruktion
- anschließende lokale Suche bis zum stabilen Zustand

Iterated-Local-Search (ILS)[GLL15]

- führt auf eine zulässige Tour lokale Verbesserungen aus bis zum vermeintlichen Optimum
- Störungen auf diese Tour $\Rightarrow$ verlassen der jetzigen Suchregion für weitere Verbesserungen

Variable-Neighborhood-Search (VNS)[PFS19]

- nutzt mehrere Stufen von Nachbarschaften $\rightarrow$ erst kleine Änderungen an der Tour, dann größere z.B. Segmentverschiebungen
- nach einem Shake wird eine lokale Suche durchgeführt
- ein Shake ist eine konkrete zufällige Störung einer aktuellen Tour innerhalb einer Nachbarschaft
- bringt die aktuelle Ebene eine Verbesserung geht es zurück zur kleinsten Nachbarschaft, sonst wird die nächstgrößere ausprobiert

Iterated-Local-Search (ILS)[GLL15]

- führt auf eine zulässige Tour lokale Verbesserungen aus bis zum vermeintlichen Optimum
- Störungen auf diese Tour $\Rightarrow$ verlassen der jetzigen Suchregion für weitere Verbesserungen

Variable-Neighborhood-Search (VNS)[PFS19]

- nutzt mehrere Stufen von Nachbarschaften $\rightarrow$ erst kleine Änderungen an der Tour, dann größere z.B. Segmentverschiebungen
- nach einem Shake wird eine lokale Suche durchgeführt
- ein Shake ist eine konkrete zufällige Störung einer aktuellen Tour innerhalb einer Nachbarschaft
- bringt die aktuelle Ebene eine Verbesserung geht es zurück zur kleinsten Nachbarschaft, sonst wird die nächstgrößere ausprobiert

Bewertung erfolgt primär auf Score und sekundär auf die Distanz

Forschungsfragen & Ziele

Zentrale Fragen

- "Welche Graphenmerkmale eignen sich zur Klassifikation?"
- "In welchem Maße verbessern sich Lösungsqualität und Laufzeit gegenüber klassischen Heuristiken?"

Erreichbarkeit dieser Ziele durch:

- Random-Forest-Modell für per-Instance-Algorithmenauswahl[Bre01]
- vergleich mit Virtual-Best-Solver und Single-Best-Solver[Kot14; Bis+16]

Algorithmenauswahl

- Grundlage bietet das Modell des Algorithm Selection Problem nach Rice[Ric76]

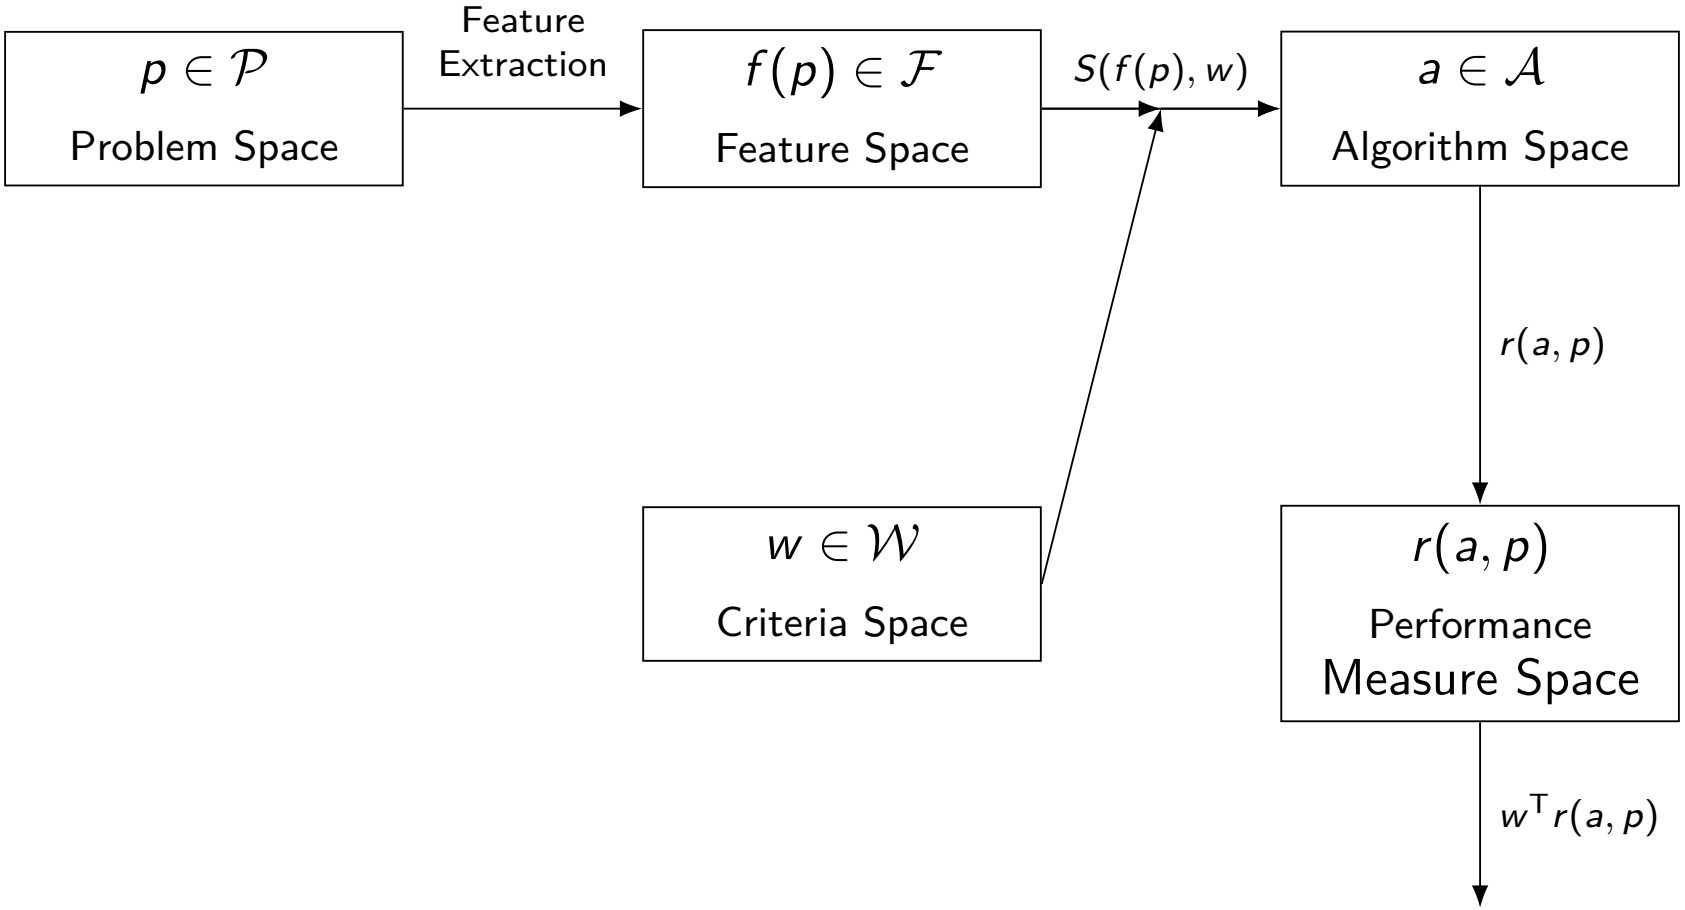

Abb. 1: Schema des Algorithm-Selection-Problems nach Rice[Ric76].

- Random Forest Classifier als Lernverfahren[Bre01; BS16]
  - robust gegenüber Overfitting
  - Feature Importance liefert Anhaltspunkte für Interpretierbarkeit[FRD19]
- zwei Varianten für die Modelle
  - globales Modell $\rightarrow$ ein Random Forest über alle Zeitlimits
  - per-Limit Modelle $\rightarrow$ ein Modell pro Zeitlimit

Merkmalsraum & Datengrundlage

- 3500 synthetische TTDP-Instanzen (2800 Trainings- und 700 Testinstanzen) $\rightarrow$ basierend auf Chao-Instanzen[CGW96; Gav+14]

Aspekt	Variation
Anzahl Knoten $\lvert V \rvert$	verschiedene Instanzgrößen
Räumliche Verteilung	gleichmäßig (uniform) vs. Cluster (Anzahl, Streuung)
Score-Verteilung	gleichmäßig vs. Hotspots (Anzahl, Bonus)
Budget B	direkt vorgegeben oder über Faktor τ relativ zu n und NN-Distanz
Depot-Score	mit/ohne gesonderte Behandlung des Depots (z. B. Score $= 0$)
Zufall-Seeds	verschiedene Seeds für Koordinaten und Scores

Table 1: Unterschiede bei der Instanzgenerierung

- für jede Instanz werden 57 Features für den Eingabevektor berechnet

Merkmal	Beschreibung
$\lvert V \rvert$	Anzahl der Knoten im Graphen
B	Tour-Budget (maximale zulässige Gesamtdistanz)
$\frac{B}{\lvert V \rvert}$	Budget pro Knoten
$\mathrm{dens}(G)$	Dichte des Graphen
$\overline{d}_{\mathrm{NN}}$	Mittlere Distanz zum jeweils nächsten Nachbarn
$\overline{d}$	Mittlere Paardistanz aller Knotenpaare
$\overline{\deg}$	Durchschnittlicher Knotengrad
$\overline{s}$	Mittlerer Score der Knoten

Table 2: Ausgewählte Instanzmerkmale für die Algorithmenauswahl

Versuchsaufbau

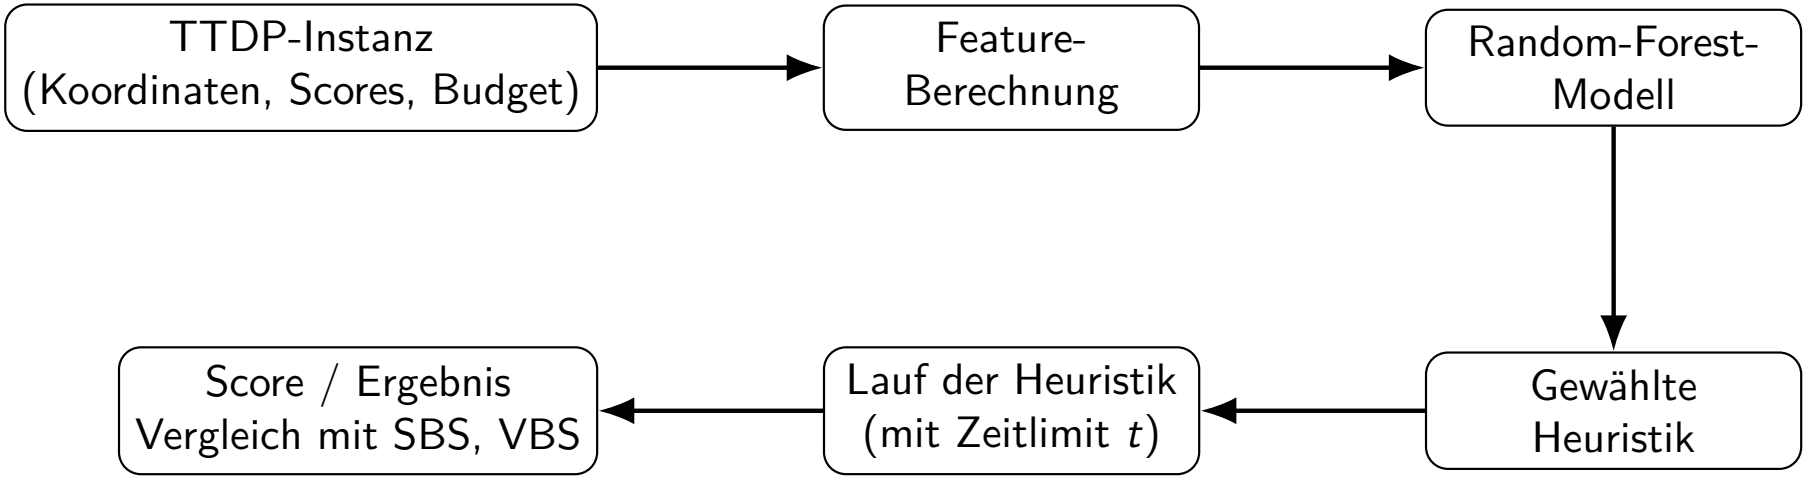

Ergebnis I: Mittlere Score vs. Zeitlimit

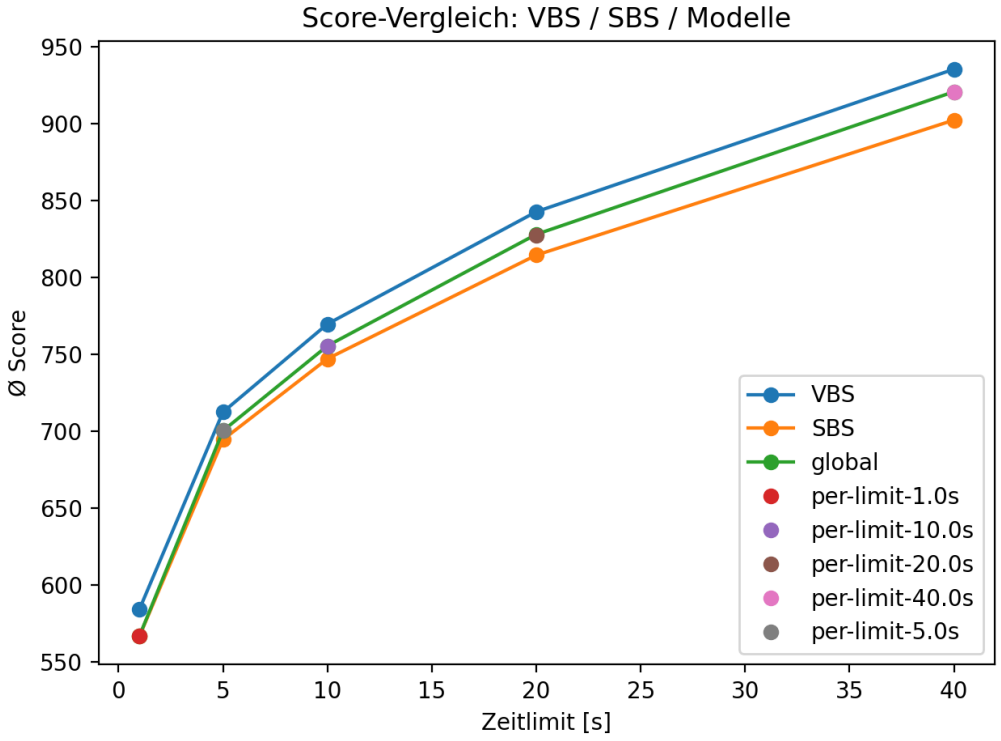

Abb. 2: Mittlerer Score im Vergleich zu SBS und VBS über die Zeitlimits

- Algorithmenauswahl verbessert den mittleren Score gegenüber dem SBS in allen Zeitlimits
- Score-Zugewinn steigt von ca. +0,15 Punkten (1 s) auf +18,41 Punkte (40 s) gegenüber SBS

Ergebnis II: Abstand zu VBS & Nähe zum Optimum

- Abstand globales Modell zu VBS: 17,1 Punkte bei 1 s Minimum 12,1 Punkte bei 5 s, danach relativ stabil bei 14–15 Punkten (10–40 s)
- SBS entfernt sich mit wachsender Zeit weiter von VBS

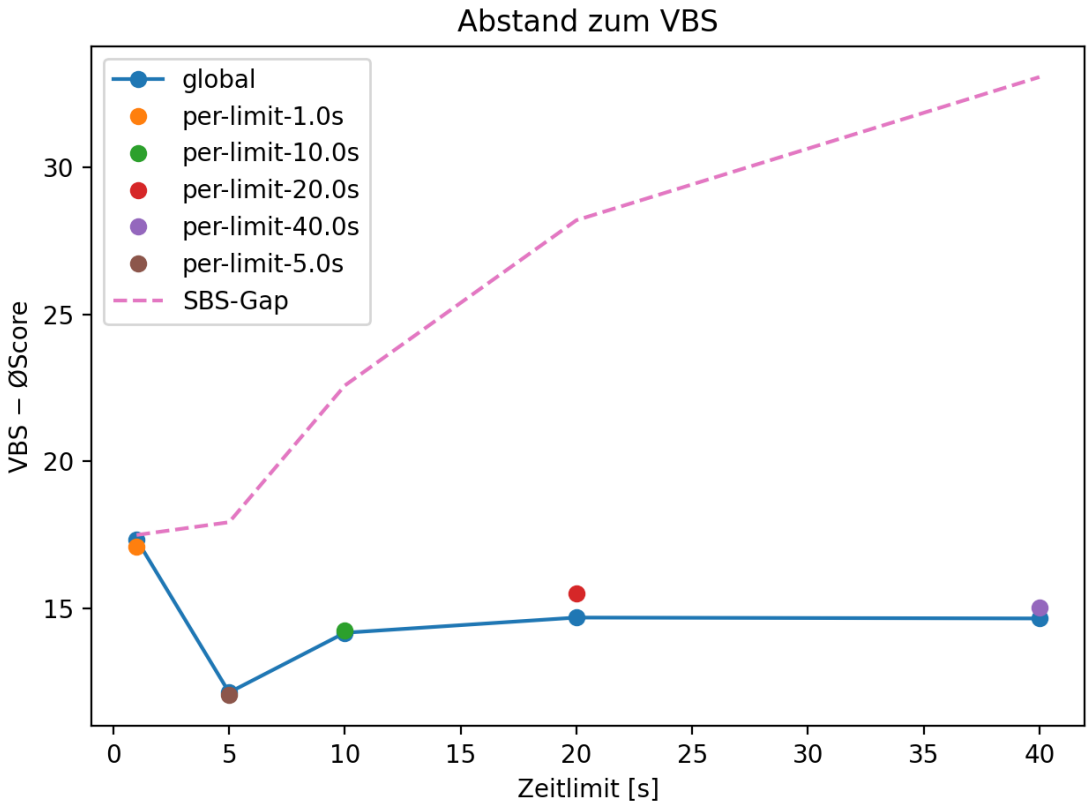

Abb. 3: Abstand zum VBS der Modelle und des SBS über die Zeitlimits

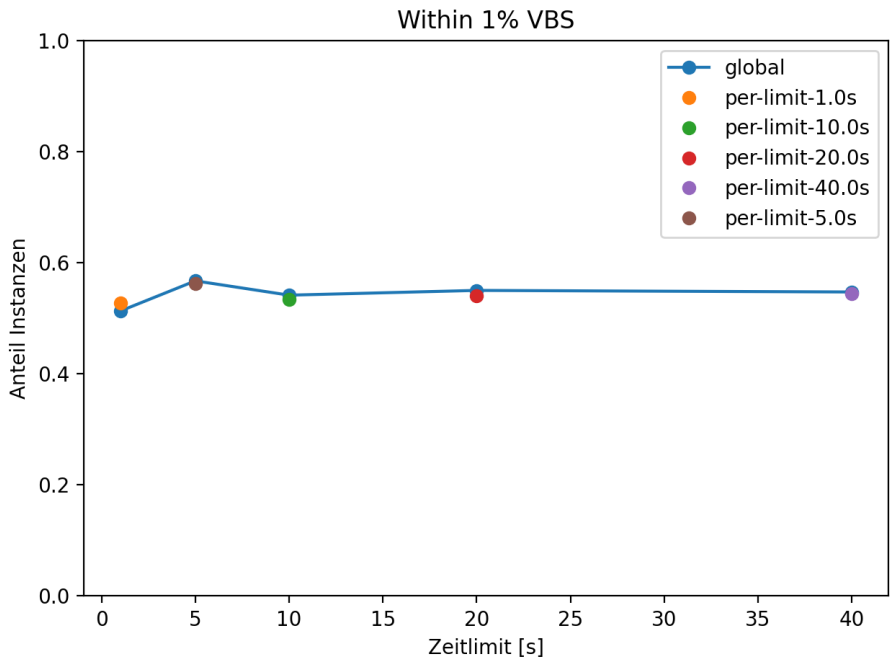

(a) $\delta = 1\,\%$

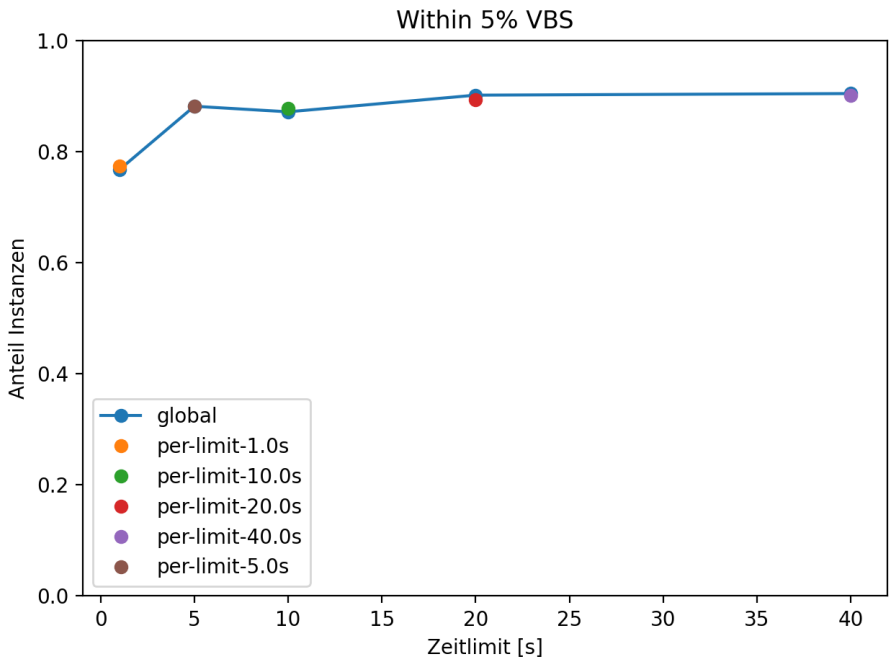

(b) $\delta = 5\,\%$

Abb. 4: Anteil der Instanzen innerhalb eines δ des VBS Scores über die Zeitlimits

$\Rightarrow$ Auswahl schließt einen großen Teil der Lücke zwischen SBS und VBS

Ergebnis III: Score-Differenz vs. SBS (Wilcoxon-Test)

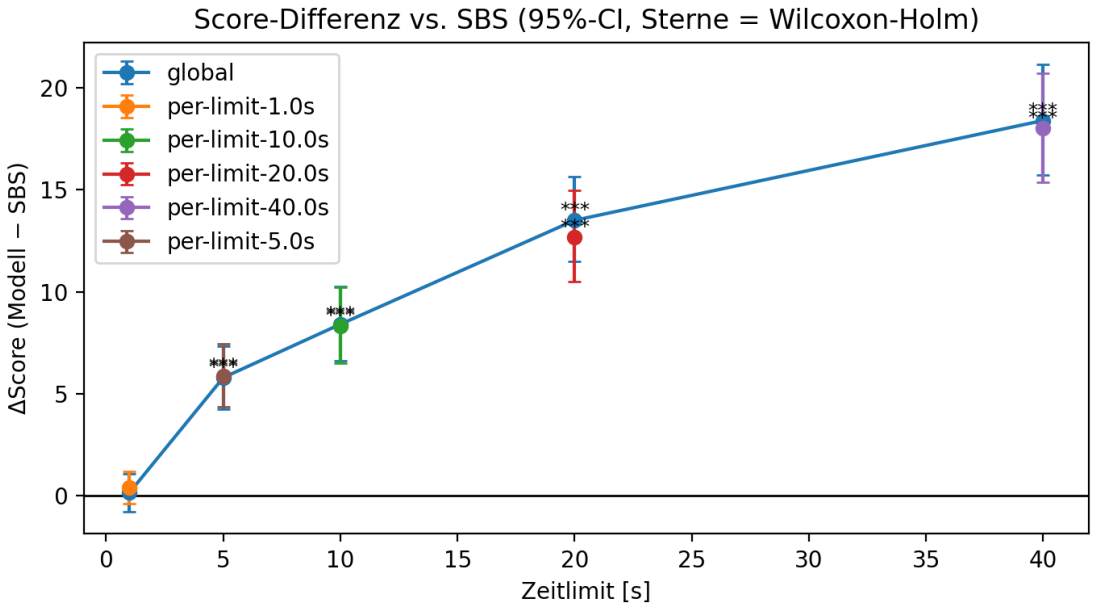

Abb. 5: Score-Differenz gegenüber SBS mit 95 %-Konfidenzintervallen je Limit. Punkte sind Mittelwerte, Balken zeigen die Intervalle.

- Pro Instanz und Zeitlimit: Abstand-Differenz $\Delta r = r_{\text{Modell}} - r_{\text{SBS}}$.
- Gepaarter Wilcoxon-Vorzeichenrangtest je Zeitlimit, Holm-korrigierte p-Werte [Wil92; Hol79]
- Bei 1 s: kein signifikanter Unterschied zum SBS
- Ab 5 s: Verbesserungen des Modells gegenüber dem SBS hochsignifikant ($p_{\text{Holm}} \ll 0{,}05$, Sterne im Plot)

Ergebnis IV: Klassifikationsgüte & Fehlerbild

	pred_grasp	pred_greedy	pred_ils	pred_vns
true_grasp	45	6	3	4
true_greedy	20	16	3	14
true_ils	16	11	21	7
true_vns	118	67	14	335

Table 3: Confusion-Matrix des globalen Random-Forest-Modells für das Zeitlimit von 1 s (Zeilen: wahre Klasse, Spalten: vorhergesagte Klasse).[SL09]

	pred_grasp	pred_greedy	pred_ils	pred_vns
true_grasp	255	4	9	2
true_greedy	8	8	2	3
true_ils	47	2	23	0
true_vns	236	8	10	83

Table 4: Confusion-Matrix des globalen Random-Forest-Modells für das Zeitlimit von 40 s (Zeilen: wahre Klasse, Spalten: vorhergesagte Klasse).[SL09]

Limit	Win [%]	Tie [%]	Loss [%]	$p_{\geq \mathrm{SBS}}$ [%]
1 s	12,4	79,4	8,1	91,9
5 s	29,4	61,7	8,9	91,1
10 s	36,6	52,4	11,0	89,0
20 s	42,0	51,3	6,7	93,3
40 s	47,6	48,0	4,4	95,6

Table 5: scorebasiertes Win–Tie–Loss gegen den SBS (globales Modell), Anteile in %.

Limit	Win [%]	Tie [%]	Loss [%]	$p_{\geq \mathrm{SBS}}$ [%]
1 s	11,3	82,0	6,7	93,3
5 s	29,9	61,0	9,1	90,9
10 s	37,4	51,4	11,1	88,9
20 s	41,7	50,4	7,9	92,1
40 s	47,0	47,9	5,1	94,9

Table 6: scorebasiertes Win–Tie–Loss gegen den SBS (per-Limit Modelle), Anteile in %.

Diskussion & Einordnung

Kernbefunde

- Algorithmenauswahl bringt im Mittel robuste Scoregewinne gegenüber dem SBS
- Abstand zu VBS bleibt klein, besonders ab mittleren Zeitlimits

Fehlerbild

- Hauptverwechslung zwischen starken Verfahren $\rightarrow$ Verluste meist gering

Stärken des Ansatzes

- robuste, datengetriebene Entscheidung
- gute Übertragbarkeit auf ähnliche Problemklassen

Grenzen

- nur synthetische Instanzen, keine realen Datensätze
- nur eine bestimmte TTDP-Variante (Rundtour, metrischer Graph, deterministische Scores)

Ausblick

- Entscheidungen bei Unsicherheit
  - "zweiter Versuch" bei knappen Fällen
- Wahl zwischen global und per-Limit automatisieren
- Robustheit auf anderen Instanzklassen prüfen (andere Größen, Dichten, verrauschte Scores)

Fazit

- KI-gestützte Algorithmenauswahl auf TTDP funktioniert zuverlässig
- Im Mittel klare Gewinne gegenüber dem Single Best Solver
- Leistung nahe an der VBS-Obergrenze, Fehler meist wenig kritisch
- Solider Baustein für praktische Routenplanungssysteme und weitere Forschung

Literaturverzeichnis I

[Bis+16] Bernd Bischl et al. "ASlib: A Benchmark Library for Algorithm Selection". In: *Artificial Intelligence* 237 (2016), pp. 41–58. DOI: 10.1016/j.artint.2016.04.003.

[Bre01] Leo Breiman. "Random Forests". In: *Machine Learning* 45.1 (Oct. 2001), pp. 5–32. DOI: 10.1023/A:1010933404324.

[BS16] Gérard Biau and Erwan Scornet. "A random forest guided tour". In: *TEST* 25.2 (June 2016), pp. 197–227. DOI: 10.1007/s11749-016-0481-7.

[CGW96] I-Ming Chao, Bruce L. Golden, and Edward A. Wasil. "The team orienteering problem". In: *European Journal of Operational Research* 88.3 (1996), pp. 464–474. DOI: 10.1016/0377-2217(94)00289-4.

Literaturverzeichnis II

[Die25] Reinhard Diestel. *Graph Theory*. 6th ed. Vol. 173. Graduate Texts in Mathematics. Hardcover: 13 Dec 2024; eBook: 20 Jan 2025. Berlin, Heidelberg: Springer, 2025. DOI: 10.1007/978-3-662-70107-2.

[DMV95] M. Dell'Amico, F. Maffioli, and P. Värbrand. "On Prize-collecting Tours and the Asymmetric Travelling Salesman Problem". In: *International Transactions in Operational Research* 2.3 (1995), pp. 297–308. DOI: 10.1111/j.1475-3995.1995.tb00023.x.

[FDG05] Dominique Feillet, Pierre Dejax, and Michel Gendreau. "Traveling Salesman Problems with Profits". In: *Transportation Science* 39.2 (2005), pp. 188–205. DOI: 10.1287/trsc.1030.0079.

Literaturverzeichnis III

[FRD19] Aaron Fisher, Cynthia Rudin, and Francesca Dominici. "All Models are Wrong, but Many are Useful: Learning a Variable's Importance by Studying an Entire Class of Prediction Models Simultaneously". In: *Journal of machine learning research : JMLR* 20 (Jan. 2019).

[Gav+14] Damianos Gavalas et al. "A survey on algorithmic approaches for solving tourist trip design problems". In: *Journal of Heuristics* 20.3 (2014), pp. 291–328. DOI: 10.1007/s10732-014-9242-5.

[GLL15] Aldy Gunawan, Hoong Chuin Lau, and Kun Lu. "An Iterated Local Search Algorithm for Solving the Orienteering Problem with Time Windows". In: *Evolutionary Computation in Combinatorial Optimization (EvoCOP 2015)*. Vol. 9026. LNCS. Cham: Springer, 2015, pp. 61–73. DOI: 10.1007/978-3-319-16468-7_6.

Literaturverzeichnis IV

[GLV87] Bruce L. Golden, Larry Levy, and Rakesh Vohra. "The orienteering problem". In: *Naval Research Logistics (NRL)* 34.3 (1987), pp. 307–318. DOI: https://doi.org/10.1002/1520-6750(198706)34:3<307::AID-NAV3220340302>3.0.CO;2-D.

[GP02] Gregory Gutin and Abraham P. Punnen, eds. *The Traveling Salesman Problem and Its Variations*. Vol. 12. Combinatorial Optimization. Dordrecht: Kluwer Academic Publishers, 2002. DOI: 10.1007/b101971.

[Hol79] Sture Holm. "A Simple Sequentially Rejective Multiple Test Procedure". In: *Scandinavian Journal of Statistics* 6.2 (1979), pp. 65–70. URL: http://www.jstor.org/stable/4615733.

[Hut+14] Frank Hutter et al. "Algorithm Runtime Prediction: Methods & Evaluation". In: *Artificial Intelligence* 206 (2014), pp. 79–111. DOI: 10.1016/j.artint.2013.10.003.

Literaturverzeichnis V

[Kot14] Lars Kotthoff. "Algorithm Selection for Combinatorial Search Problems: A Survey". In: *AI Magazine* 35.3 (2014), pp. 48–60. DOI: 10.1609/aimag.v35i3.2460.

[KZ16] Morteza Keshtkaran and Koorush Ziarati. "A novel GRASP solution approach for the Orienteering Problem". In: *Journal of Heuristics* 22.5 (2016), pp. 699–726. DOI: 10.1007/s10732-016-9316-7.

[New11] M. E. J. Newman. *Networks*. 2nd ed. Oxford: Oxford University Press, 2011.

[PFS19] Robert Pěnička, Jan Faigl, and Martin Saska. "Variable Neighborhood Search for the Set Orienteering Problem and its application to other Orienteering Problem variants". In: *European Journal of Operational Research* 276.3 (2019), pp. 816–825. DOI: 10.1016/j.ejor.2019.01.047.

Literaturverzeichnis VI

[Ric76] John R. Rice. "The Algorithm Selection Problem". In: *Advances in Computers*. Ed. by M. Rubinoff and M. C. Yovits. Vol. 15. New York: Academic Press, 1976, pp. 65–118. DOI: 10.1016/S0065-2458(08)60520-3.

[SL09] Marina Sokolova and Guy Lapalme. "A systematic analysis of performance measures for classification tasks". In: *Information Processing & Management* 45 (July 2009), pp. 427–437. DOI: 10.1016/j.ipm.2009.03.002.

[Tsi84] Thomas Tsiligirides. "Heuristic Methods Applied to Orienteering". In: *Journal of the Operational Research Society* 35.9 (1984), pp. 797–809. DOI: 10.1057/jors.1984.162.

[TV14] Paolo Toth and Daniele Vigo. *Vehicle Routing*. Ed. by Daniele Vigo and Paolo Toth. Philadelphia, PA: Society for Industrial and Applied Mathematics, 2014. DOI: 10.1137/1.9781611973594.

Literaturverzeichnis VII

[VSO11] Pieter Vansteenwegen, Wouter Souffriau, and Dirk Van Oudheusden. "The orienteering problem: A survey". In: *European Journal of Operational Research* 209.1 (2011), pp. 1–10. DOI: 10.1016/j.ejor.2010.03.045.

[Wil92] Frank Wilcoxon. "Individual Comparisons by Ranking Methods". In: *Breakthroughs in Statistics: Methodology and Distribution*. Ed. by Samuel Kotz and Norman L. Johnson. New York, NY: Springer New York, 1992, pp. 196–202. DOI: 10.1007/978-1-4612-4380-9_16.

[WS98] Duncan J. Watts and Steven H. Strogatz. "Collective dynamics of 'small-world' networks". In: *Nature* 393.6684 (1998), pp. 440–442. DOI: 10.1038/30918.

Feature-Importance (globales Modell)

- Permutationsbasierte Feature-Importance auf dem F_1-Score der Klassen[Bre01; FRD19]
- Aggregation der Importance über alle vier Klassen (Greedy, GRASP, ILS, VNS)
- Zeitlimit und Budget-bezogene Merkmale dominieren die Vorhersage

Merkmal	Interpretation	$\overline{\mathrm{PI}}$
`limit_s`	Zeitlimit der Heuristik	0,206
`budget`	Tour-Budget B	0,086
`budget_per_node`	Budget pro Knoten $B/\lvert V\rvert$	0,078
`nodes`	Knotenzahl $\lvert V\rvert$	0,026
`mst__degree_avg`	mittlerer Grad im MST	0,023
`density`	Dichte des Graphen	0,010
`rad_0_5__degree_avg`	mittlerer Grad im Radiusgraph $r = 0{,}5$	0,009
`mst__mst_edge_max_per_sqrtA`	max. MST-Kante / $\sqrt{\text{Fläche}}$	0,006

Table 7: Wichtigste Merkmale im globalen Random-Forest-Modell (mittlere Permutationsimportance über alle Klassen).

Feature-Importance pro Heuristikklasse

Klasse	wichtige Merkmale	Bemerkung
GRASP	`limit_s`, `budget_per_node`, `budget`, `nodes`, `mst__degree_avg`	reagiert stark auf Budget/Limit
Greedy	`limit_s`, `nodes`, `mst__degree_avg`, `budget_per_node`, `budget`	einfach, profitiert von „kleinen“ Instanzen
ILS	`budget`, `budget_per_node`, `limit_s`, `density`, `rad_0_5__degree_avg`	bevorzugt dichte, „reiche“ Instanzen
VNS	`limit_s`, `nodes`, `mst__degree_avg`, `budget_per_node`, `budget`	braucht eher mehr Zeit und Struktur

Table 8: Top-Merkmale je Klasse im globalen Modell (Permutationsimportance pro Klasse).

- Alle Klassen hängen stark von Limit und Budget ab
- Strukturelle Merkmale (MST, Dichte, Radiusgraph) differenzieren eher zwischen „lokalen“ und „intensiven“ Verfahren